林知远 AI 全栈工程师

实习经历

2026.07-2026.10 **AI 全栈工程师实习**

项目介绍：Tiny Office 是一款结合办公室经营、角色养成和 AI 对话的应用。玩家招募 AI 角色(Agent)作为“办公室员工”，通过人格卡片定制性格与背景，通过**技能(Skill)卡片**定制行为表现，在办公室场景中观察、互动和分享小人。

- **服务端链路**：主要**负责 agent_hub 模块的设计与开发**，围绕玩家与角色的连续对话，构建 agent 链路，开发上下文编译、工具执行及 SSE 输出相关功能。处理**取消、超时和断流**场景，使客户端能够对应展示对话状态。**搭建统一**的模型调用入口 **Gateway**，对接大模型服务、统一处理模型响应，实现流式接收、超时与重试。协同处理玩家中止回复、请求超时等情况，支持客户端查询实际执行结果并正确展示对话状态。
- **工具与 Skill**：**开发工具调用与结果回填相关功能**，使角色处理请求时使用对应能力，并基于执行结果继续回复。**编写并调优人物角色性格类与功能类 Skill 提示词**：性格类定义角色的语气、表达习惯，功能类明确食谱、解梦、复盘等任务的触发条件、能力边界等，并根据角色装备动态加载。调整工作请求与闲聊的判断；闲聊内容按语义分段，便于逐段呈现。
- **后端架构**：针对**多用户并发 Agent 对话**的情况，采用 Redis 缓存会话上下文、Agent/Skill 配置和流式响应状态，通过**分布式锁**保证同一会话请求串行执行，结合**幂等校验和用户级限流**避免重复调用模型及消息乱序；配合 SSE 流式返回、超时重试和异常恢复机制，**保障高并发下**的对话状态、Token 预算和消息落库一致性。
- **界面与场景交互**：重点**优化角色配置页面的 UI 与交互**流程，为技能装配增加动态反馈，使装备变化直观可见。优化“正在输入”状态和分段消息的展示，协调回复节奏与状态切换；**调试** Flame 办公室场景中的角色移动、障碍物绕行与碰撞处理，提升场景交互的流畅度。

项目经历

2026.04-2026.07 **AI 应用代码安全的自进化审查 Agent** **个人**

项目背景：针对 AI 应用代码的提示词注入、工具越权、模型输出误用等风险，开发多智能体代码审查平台：自建后端服务以及多个 Agent 协作审查，并把每次审查的轨迹采集、筛选、标注成数据，本地 **LoRA 微调后灰度回灌**，实现“越用越准”的自进化闭环。

技术栈：Python, Harness Engineering, Muiti-Agent, Skill, PostgreSQL, Docker

- **链路设计**：自写 Agent 运行循环与工具注册表，实现 Checkpoint，支持**断点续跑、双预算、重试/死信**；每个 LLM 步骤的上下文、回复与工具结果完整落库，失败可按规定格式回放；配套“结论必须能在轨迹中找到”的一致性校验，122 项单测兜底。
- **四层智能体协作**：Lead 委派→双 worker 按**特定工具权限并行**执行→Critic 盲审→Lead 综合四层架构，**高危支持一轮返工**，降低**单 Agent 幻觉**；垂直 6 类 AI 风险的确定性冷扫描器在自建语料 Precision1.0/Recall0.83/F1 0.91，干净 Diff 零误报。
- **上下文与工具设计**：按风险信号**对 Diff 的 hunk 和符号排序**，在 Token 预算内**保留关键代码**，并对工具观察和跨会话记忆限额、标记不可信来源。工具注册表**按角色限制可见工具**及调用权限，统一校验参数、封装结果并生成证据 ID，使模型结论能够对应到具体代码和工具观察。
- **自进化与评测**：将误报、漏报和审查轨迹**沉淀为结构化反馈**，分别**演进**可回滚 Skill、提示词版本和本地 LoRA 权重。建立基于 100 个受控 PR Diff 样本的端到端评测，PR Review 准确率达 92%。

技能特长

- **语言：**英语四级、英语六级（549）
- **Python 基础：**熟悉 Python 语法、数据结构、面向对象及异步编程等
- **Agent 架构：**熟悉 Prompt、Context、Tool Use、Skill、Memory、Checkpoint 等核心机制
- **AI Coding：**熟练利用 Codex、Claude Code 结合代码理解，问题排查，方案设计，实现文档整理